

INSTITUTO INFNET

TP1 - Engenharia de Prompts para Ciência de Dados

26 de outubro de 2026

Professor: Claudio Bonel Da Silva

Aluno: Lucas Chrystello Pederneiras

Disciplina: Engenharia de Prompts para Ciência de Dados

Curso: Ciências de Dados

1. IA Generativa e IA Preditiva

A diretoria perguntou: “IA generativa é a mesma coisa que o modelo que prevê quais clientes vão cancelar?”. Escreva um texto de 8 a 12 linhas, em linguagem acessível a quem não é da área de dados, que explique o que é inteligência artificial generativa e em que ela difere da IA preditiva (que classifica ou estima um valor). Inclua dois exemplos de uso na NetBoa Fibra: uma tarefa preditiva e uma tarefa generativa.

R: IA generativa é a tecnologia que cria conteúdo novo, como textos, resumos ou imagens, a partir de uma instrução escrita. Ela aprende padrões em grandes volumes de exemplos e produz algo “inédito” que segue esses padrões. A IA preditiva funciona de outro modo: analisa dados históricos e devolve uma classificação ("este cliente vai cancelar: sim ou não?") ou um valor estimado ("qual será a receita do mês que vem?"). Portanto, o modelo que prevê cancelamentos não é generativo, embora ambos usem aprendizado de máquina. A preditiva escolhe entre respostas definidas de antemão; a generativa escreve a resposta. Na NetBoa Fibra, um exemplo preditivo é estimar a probabilidade de cancelamento de cada cliente com base em quedas, atrasos e reclamações. Um exemplo generativo é redigir um resumo de três linhas de cada chamado longo para a equipe de atendimento. (**Gerado por Claude Sonnet 5.5 Thinking, revisado e adaptado por mim**).

2. Modelos Grandes de Linguagem (LLMs)

O comitê quer saber o que significa a sigla LLM. Em 8 a 12 linhas, explique o que é um modelo grande de linguagem: sua relação com a IA generativa, o que significa “grande” (número de parâmetros e volume de dados de treinamento), a arquitetura em que a maioria desses modelos se baseia e a tarefa básica que eles executam (prever o próximo token). Explique, com base nisso, por que um LLM consegue classificar um chamado a partir de uma instrução escrita em português. Cite ao menos uma fonte (livro da bibliografia da disciplina ou documentação oficial).

R: A sigla LLM significa Large Language Model (Modelo Grande de Linguagem), um pilar da IA Generativa capaz de processar e criar textos. O termo "grande" refere-se aos seus bilhões de parâmetros na rede neural e ao massivo volume de dados de treinamento, aspectos que Valentina Alto (Building LLM Powered Applications) destaca na escolha e no uso responsável desses sistemas. Segundo Sinan Ozdemir (Quick Start Guide to Large Language Models) e Mike Taylor (Prompt Engineering for Generative AI), tais modelos baseiam-se na arquitetura Transformer e executam uma tarefa básica estatística: prever o próximo token (palavra ou parte dela) mais provável dada uma sequência anterior. É assim que um LLM classifica um chamado via instrução em português: ao ler o comando (prompt)

e o relato, a arquitetura analisa o contexto semântico do idioma e gera a categoria correta simplesmente calculando quais são os próximos tokens mais coerentes para responder àquela instrução (**texto revisado por Gemini 4 Argon**).

Referências:

ALTO, Valentina. Building LLM Powered Applications. Capítulos: "Choosing an LLM for Your Application" e "Responsible AI".

OZDEMIR, Sinan. Quick Start Guide to Large Language Models. Capítulo: "Introduction to Large Language Models".

TAYLOR, Mike. Prompt Engineering for Generative AI. Capítulo: "Introduction to Large Language Models for Text Generation".

3. Pré-treinamento de LLMs

Um diretor perguntou: “Se o modelo já aprendeu com tanta coisa, por que ele erra o jargão da nossa empresa?”. Descreva o processo de pré-treinamento de um LLM em etapas, da coleta dos dados até o modelo pré-treinado, incluindo: a origem e a preparação do conjunto de textos, a tokenização, o objetivo de treinamento (prever o próximo token) e o ajuste dos parâmetros. Complemente com um diagrama simples do fluxo, feito por você. Em seguida, responda à pergunta do diretor, explicando o que o pré-treinamento não inclui (os dados internos da empresa e o que aconteceu depois da data de corte do treinamento) e diferenciando o pré-treinamento dos ajustes posteriores, como o ajuste por instruções e por feedback humano.

R: O pré-treinamento de um LLM inicia-se com a coleta massiva de textos públicos da internet e livros, que passam por uma preparação rigorosa de limpeza, filtragem e remoção de ruídos. Em seguida, ocorre a tokenização, processo que divide o texto limpo em unidades menores (tokens) convertidas em representações numéricas. Com os dados prontos, o objetivo de treinamento do modelo é puramente estatístico: prever o próximo token de uma sequência com base nos anteriores. A cada tentativa, o algoritmo compara sua previsão com o texto original e realiza o ajuste matemático gradual de seus bilhões de parâmetros na rede neural, resultando ao final no modelo pré-treinado (modelo base).

Diagrama feito com mermaid.live (código em **fluxo_mermaid.ipynb**):



Em resposta ao diretor, o modelo erra o jargão corporativo porque o pré-treinamento abrange apenas dados públicos gerais e fica estático em uma data de corte, não incluindo os dados internos e confidenciais da empresa nem os fatos ou termos surgidos após o término do treinamento. Além disso, é preciso diferenciar o pré-treinamento, que apenas dá ao modelo uma compreensão geral da língua, dos ajustes posteriores realizados sobre ele. Enquanto o ajuste por instruções (instruction tuning) treina o modelo base com exemplos para que ele aprenda a seguir comandos e o ajuste por feedback humano (RLHF) alinha suas respostas para torná-las úteis e seguras, o aprendizado de siglas e jargões internos exige etapas específicas de adaptação, como inserir esse contexto no próprio prompt ou realizar um ajuste fino (fine-tuning) com os documentos da empresa (**texto revisado por Gemini 4 Argon**).

4. Embeddings

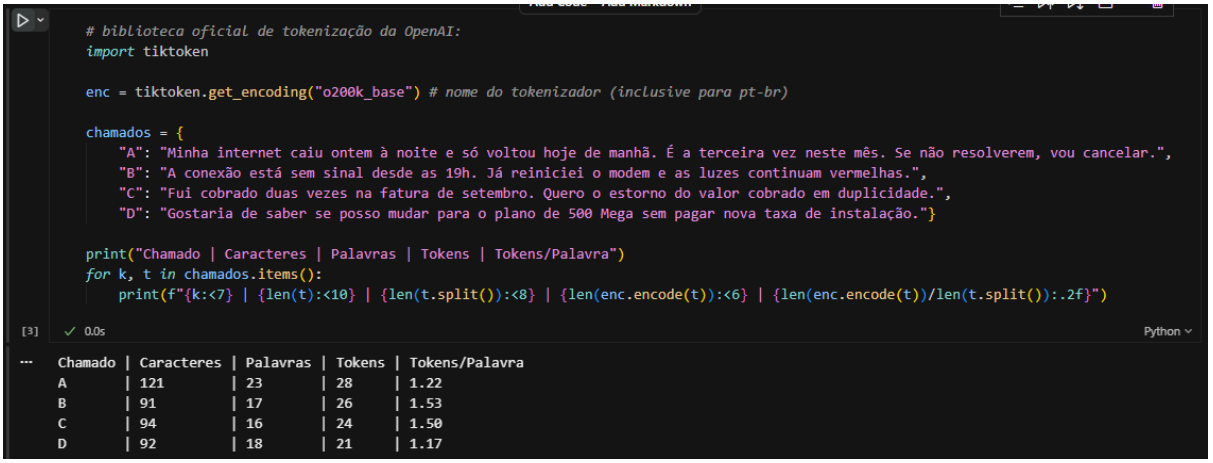
A área de atendimento quer encontrar chamados parecidos mesmo quando as palavras são diferentes. Explique o conceito de embeddings em LLMs: o que é, como um texto é representado e o que significa dizer que dois textos estão “próximos”. Em seguida, usando os chamados A a D da tabela do estudo de caso, indique qual par você espera que fique mais próximo e qual par ficaria mais distante no espaço de embeddings, justificando pelo sentido dos textos, e não pelas palavras em comum. Por fim, descreva uma aplicação dos embeddings para a NetBoa Fibra.

R: Os embeddings (representações vetoriais) são listas de números que funcionam como coordenadas em um mapa de ideias, permitindo ao computador traduzir e comparar o significado real de um texto. Dizer que dois textos estão "próximos" nesse espaço significa que suas coordenadas ficaram vizinhas porque tratam do mesmo assunto ou intenção, mesmo usando palavras totalmente diferentes. Nos exemplos da NetBoa Fibra, o par mais próximo será A e B, pois ambos relatam o mesmo problema técnico de queda de sinal de internet, embora A fale em "internet caiu" e B cite "luzes do modem". Já o par mais distante será A e D (ou B e D), pois enquanto A é uma reclamação urgente de falha técnica com ameaça de cancelamento, D é uma dúvida sobre mudança de plano. Na prática, a NetBoa pode aplicar embeddings para agrupar automaticamente chamados com o mesmo defeito técnico descritos de formas distintas pelos clientes, padronizando a triagem e identificando quedas regionais imediatamente (**texto revisado por Gemini 4 Argon**).

5. Tokenização

Defina tokenização e explique por que ela importa para os LLMs (custo de uso, limite de contexto e desempenho em diferentes idiomas). Em seguida, escolha uma ferramenta de tokenização (vista em aula ou pesquisada por você), tokenize os chamados A a D e monte uma tabela com: chamado, número de caracteres, número de palavras, número de tokens e tokens por palavra. Informe a ferramenta e o tokenizador usados, com a data do teste, e anexe a evidência (captura de tela ou trecho de código). Calcule a média de tokens por chamado e estime o total de tokens dos 40 mil chamados de um mês, explicando em duas ou três linhas o que essa estimativa significa para o custo e para o limite de contexto.

R: Tokenização é a divisão do texto em pedaços menores, os tokens (palavras inteiras, partes de palavras ou sinais de pontuação), convertidos em números para o modelo processar. Ela importa por três motivos: o custo é cobrado por token processado; o limite de contexto, que é a quantidade máxima de texto que o modelo lê de uma vez, é medido em tokens; e o idioma afeta o consumo, pois o português tende a gerar mais tokens por palavra que o inglês, por causa de acentos, conjugações e palavras longas. Usando a biblioteca tiktoken, da OpenAI, com o tokenizador o200k_base, em 26/10/2026, obtive os resultados da tabela acima. A média foi de 24,75 tokens por chamado, e a estimativa mensal é de 990.000 tokens (24,75 × 40.000).



```
# biblioteca oficial de tokenização da OpenAI:
import tiktoken

enc = tiktoken.get_encoding("o200k_base") # nome do tokenizador (inclusive para pt-br)

chamados = {
    "A": "Minha internet caiu ontem à noite e só voltou hoje de manhã. É a terceira vez neste mês. Se não resolverem, vou cancelar.",
    "B": "A conexão está sem sinal desde as 19h. Já reiniciei o modem e as luzes continuam vermelhas.",
    "C": "Fui cobrado duas vezes na fatura de setembro. Quero o estorno do valor cobrado em duplicidade.",
    "D": "Gostaria de saber se posso mudar para o plano de 500 Mega sem pagar nova taxa de instalação."}

print("Chamado | Caracteres | Palavras | Tokens | Tokens/Palavra")
for k, t in chamados.items():
    print(f"{k:<7} | {len(t):<10} | {len(t.split()):<8} | {len(enc.encode(t)):<6} | {len(enc.encode(t))/len(t.split()):.2f}")
```

```
[3]  ✓ 0.0s                                                                    Python
...  Chamado | Caracteres | Palavras | Tokens | Tokens/Palavra
     A       | 121        | 23       | 28     | 1.22
     B       | 91         | 17       | 26     | 1.53
     C       | 94         | 16       | 24     | 1.50
     D       | 92         | 18       | 21     | 1.17
```

(**Código gerado por Gemini 4 Argon**)

Com a instrução e a resposta de cada chamada, o consumo chega a alguns milhões de tokens, o que indica custo baixo (a confirmar com o preço oficial). Cada chamado tem cerca de 25 tokens, muito abaixo do limite de contexto, então eles devem ser processados um a um ou em pequenos lotes (**texto revisado por Claude Sonnet 5.5 Thinking**).

Código encontrado em “token.ipynb”.

6. Critérios para Escolher um LLM

Monte uma tabela com, no mínimo, 6 critérios que a NetBoa Fibra deve usar para escolher o LLM que lerá os chamados. Para cada critério, informe: por que ele importa neste caso, como medi-lo ou verificá-lo (por exemplo, um teste com chamados reais anonimizados) e o peso que você atribui (alto, médio ou baixo). Entre os critérios devem aparecer, pelo menos: custo, qualidade em português, privacidade e proteção de dados (LGPD) e limite de contexto.

R:

Critérios para LLM

Critério	Por que importa neste caso	Como medir ou verificar	Peso
Qualidade em português	Chamados têm gírias, erros de digitação e abreviações	Testar com 200 a 300 chamados reais anonimizados, rotulados por humanos, e medir acertos de assunto, sentimento e urgência	Alto
Privacidade e LGPD	Os chamados contêm dados pessoais de clientes	Analisar contrato e política de dados: uso dos dados para treinamento, local de armazenamento, retenção, acordo de tratamento de dados, possibilidade de execução própria	Alto
Custo	São 40 mil chamados por mês, de forma recorrente	Tokens por chamado (tarefa 5) × preço oficial por token, mais infraestrutura se for hospedado	Alto
Consistência das respostas	O problema atual é classificar casos parecidos de modos diferentes	Repetir o mesmo chamado várias vezes e medir a variação, com configuração de baixa aleatoriedade	Alto
Limite de contexto	Define quanto texto cabe por chamada (instrução, exemplos e chamado)	Conferir na documentação do modelo e comparar com a média de tokens da tarefa 5	Médio
Latência e capacidade de processamento	O lote mensal precisa terminar em horas, não em dias	Medir o tempo de uma amostra e extrapolar para 40 mil	Médio
Facilidade de integração	Precisa conectar ao sistema de chamados	Verificar API, saída estruturada (JSON) e bibliotecas disponíveis	Médio
Estabilidade do fornecedor	Modelos são atualizados e descontinuados	Verificar política de versões e prazos de descontinuação	Baixo

(**texto revisado por Claude Sonnet 5.5 Thinking**)

7. Principais Modelos do Mercado

Faça um levantamento atualizado de pelo menos 5 modelos de linguagem disponíveis hoje, de pelo menos 4 fornecedores ou organizações diferentes, incluindo ao menos 2 modelos proprietários e 2 modelos abertos. Para cada um, informe: nome e versão, organização responsável, tipo de licença, forma de acesso (API, aplicativo ou pesos para execução própria) e a fonte oficial consultada, com a data da consulta. Como os modelos mudam rapidamente, informações sem fonte e sem data não serão consideradas.

R:

Principais Modelos LLM(Table Data)

Modelo e versão	Organização	Licença	Forma de acesso	Fonte oficial consultada	Data da consult
GPT-6 Astra	OpenAI	Proprietária	API	https://developers.openai.com/api/docs/models/gpt-6-astra	26/10/2026
Claude Sonnet 5.5	Anthropic	Proprietária	API (Claude Platform) e aplicativos Claude	https://www.anthropic.com/claude-sonnet-5-5	26/10/2026
Gemini 4 Argon	Google	Proprietária	Gemini API e Google AI Studio	https://ai.google.dev/gemini-api/docs/models/gemini-4-argon?hl=pt-br	26/10/2026
Grok 4.7	SpaceXAI	Proprietária	Grok API, Grok Build, Cursor, ferramentas de terceiros e plataformas de nuvem	https://x.ai/news/grok-4-7	26/10/2026
DeepSeek V4.1 Flash	DeepSeek	Pesos para execução própria no Hugging Face; API da DeepSeek	Pesos para execução própria no Hugging Face; API da DeepSeek (confirmada para o V4.1 Flash na página de lançamento)	https://huggingface.co/deepseek-ai/DeepSeek-V4.1-Flash-1017	26/10/2026
Qwen3.8-Flash-Next	Qwen (Grupo Alibaba)	qwen-community-1.0 (Qwen Community License 1.0)	Pesos para execução própria no Hugging Face e no ModelScope	https://huggingface.co/Qwen/Qwen3.8-Flash-Next	26/10/2026

8. Modelos Proprietários x Open-Source

Compare, em uma tabela, as vantagens e as desvantagens de modelos proprietários e de modelos abertos (open-source) para a NetBoa Fibra, considerando ao menos: custo, controle sobre os dados e privacidade, personalização, esforço de manutenção e de infraestrutura e transparência. Use como exemplos modelos do levantamento da tarefa 7 e informe a licença de cada um, pois “aberto” pode significar desde pesos disponíveis até código e dados abertos. Termine com uma conclusão de 3 a 5 linhas: em que situação da empresa cada tipo seria o mais indicado?

R:

Modelos Proprietários x Open-Source(Table Data)

Critério	Proprietários: vantagens	Proprietários: desvantagens	Abertos: vantagens	Abertos: desvantagens
Custo	Não exige comprar equipamento, e o pagamento é por uso, em tokens (pedaços de texto). O GPT-6 Astra custa US$ 10 por milhão de tokens de entrada e US$ 50 de saída, e o Claude Sonnet 5.5 custa US$ 2 e US$ 10.	O gasto cresce com o volume, e o fornecedor pode mudar os preços.	Não há cobrança por token do fornecedor do modelo, e a licença MIT do DeepSeek não cobra pelo uso.	O custo passa a ser servidores com GPU (placas de vídeo especializadas) e equipe técnica. O repositório do Qwen tem cerca de 360 GB, o que indica servidores com várias GPUs.
Dados e privacidade	O fornecedor opera a segurança da infraestrutura.	O texto dos chamados sai da NetBoa e passa por terceiros. É preciso anonimizar os dados e verificar nos termos do fornecedor se o uso para treinamento pode ser proibido, conforme a LGPD.	Rodando nos servidores da própria empresa, os dados não saem dela.	Segurança e conformidade com a LGPD passam a ser responsabilidade da NetBoa. Usar o modelo por um provedor terceiro, como o cartão do DeepSeek lista, traz de volta o risco de envio de dados.
Personalização	Bons resultados com instruções e exemplos no prompt, sem treinar nada.	O ajuste fino (treinar o modelo com exemplos próprios) depende da oferta do fornecedor, que não verifiquei para estes modelos.	Com os pesos em mãos, a empresa pode ajustar o modelo com seus chamados, dentro da licença.	Exige conhecimento técnico e uma base de chamados já classificados.
Manutenção e infraestrutura	O fornecedor cuida de servidores, atualizações e disponibilidade.	Versões podem mudar ou ser descontinuadas sem decisão da NetBoa, alterando os resultados.	A empresa escolhe quando atualizar e pode manter a versão estável.	Precisa operar GPUs, monitorar e atualizar. A equipe do Qwen3.8-Flash-Next o descreve como prévia de arquitetura, o que é um risco para produção.
Transparência	Há documentação oficial sobre preço, acesso e uso.	Pesos e dados de treinamento não são publicados, e o tamanho do modelo muitas vezes não é informado.	Pesos (abertos) e licença podem ser inspecionados, e há documentação técnica.	A transparência é parcial, porque os dados de treinamento não são publicados (ambos Qwen e DeepSeek).

Modelos proprietários são os mais indicados se a empresa NetBoa quer começar rápido, não tem equipe para operar servidores e consegue anonimizar os chamados e firmar contrato de proteção de dados. Modelos abertos fazem mais sentido se a política de privacidade proibir o envio dos chamados a terceiros, ou se o volume crescer a ponto de o custo por token superar o de manter servidores próprios. Para o piloto, a opção proprietária é mais simples, e a decisão de longo prazo deve comparar o custo de infraestrutura com o gasto em tokens (**texto revisado por Claude Sonnet 5.5 Thinking**).

9. Tamanho x Desempenho

Explique o trade-off entre o tamanho de um LLM (número de parâmetros) e o seu desempenho, considerando a qualidade das respostas, a latência, o custo por uso e os requisitos de hardware. Escolha dois modelos do seu levantamento, um de maior porte e um de menor porte (quando o fornecedor não divulgar o tamanho, diga isso e use a classificação dele, como versão compacta ou completa), e analise, em um parágrafo, qual atende melhor à classificação de 40 mil chamados por mês, usando ao menos dois dos fatores citados. Indique também uma situação em que a escolha seria a oposta.

R: O tamanho de um LLM é medido em parâmetros, os valores numéricos que o modelo ajusta no treinamento. Em geral, mais parâmetros melhoram a qualidade das respostas em tarefas difíceis, mas aumentam a latência (tempo de resposta), o custo por uso e a necessidade de hardware, sobretudo memória de GPU (placa de vídeo especializada). Modelos menores são mais rápidos e baratos, mas tendem a errar mais nos casos difíceis. Comparo o GPT-6 Astra, de maior porte, e o Qwen3.8-Flash-Next, de menor porte. A OpenAI não divulga o número de parâmetros nas fontes que encontrei (aparentemente são 4,8 trilhões e 10 trilhões de parâmetros, mas não consegui confirmar), então uso a classificação de modelo mais capaz da empresa. O Qwen3.8-Flash-Next é a versão "Flash" da família, com 125 bilhões de parâmetros principais, mais 51 bilhões de embeddings de n-grams, dos quais 6 bilhões são ativados por token (huggingface.co/Qwen/Qwen3.8-Flash-Next).

Para 40 mil chamados por mês, o GPT-6 Astra atende melhor, pelos fatores custo e hardware. Num cenário hipotético de 1.000 tokens de entrada e 100 de saída por chamado, o gasto seria de cerca de US$ 600 por mês (US$ 400 de entrada a US$ 10 por milhão e US$ 200 de saída a US$ 50 por milhão), sem hardware próprio. O Qwen não cobra por token, mas exigiria servidores com GPUs próprios (ou alugados), o que nesse volume tende a custar mais do que pagar por uso, além de ser uma prévia experimental. A escolha seria a oposta se a política de privacidade proibisse enviar os chamados a terceiros, caso em que o Qwen rodaria na infraestrutura da NetBoa, ou se o volume chegasse a milhões de chamados, quando o custo por token superaria o dos servidores próprios (**texto revisado por Claude Sonnet 5.5 Thinking)**.

10. Desafios Éticos e Limitações

Avalie os desafios éticos e as limitações de usar um LLM para ler os chamados da NetBoa Fibra. Monte uma tabela com, no mínimo, 5 riscos (entre eles: erros e alucinações na classificação, vieses, privacidade e LGPD dos dados dos clientes, transparência e responsabilidade pela decisão e conhecimento desatualizado). Para cada risco, classifique a gravidade neste caso (alta, média ou baixa), justifique e proponha uma medida de mitigação. Conclua com a sua decisão e as condições de uso, em 3 a 5 linhas: a NetBoa Fibra deve adotar o LLM, adotar com condições ou não adotar neste momento?

R:

Desafios Éticos e Limitações(Table Data)

Risco	Gravidade	Justificativa	Mitigação
Erros e alucinações na classificação	Alta	Um chamado urgente classificado como comum, como o de um cliente prestes a cancelar, gera perda de cliente. O modelo pode errar com aparente confiança	Validar com amostra rotulada por humanos, revisar manualmente casos de baixa confiança, restringir a saída a categorias fixas
Vieses	Média	O modelo pode interpretar de forma diferente linguagem informal, regionalismos ou erros de escrita, tratando clientes de modo desigual	Medir o desempenho por perfil e região, e revisar periodicamente
Privacidade e LGPD	Alta	Os chamados trazem nome, endereço, CPF e dados de consumo. Vazamento ou uso indevido gera sanções e perda de confiança	Anonimizar antes do envio, firmar contrato de proteção de dados, exigir que o fornecedor não treine com eles, definir a base legal e avaliar modelo aberto em ambiente próprio
Transparência e responsabilidade	Média	O modelo não explica de forma confiável por que classificou assim, e é preciso definir quem responde por um erro	Registrar entradas e saídas, designar um responsável humano e tratar a classificação como apoio, não como decisão final
Conhecimento desatualizado e jargão interno	Média	O modelo desconhece planos novos e termos da empresa, surgidos depois do seu treinamento	Incluir glossário e informações atuais na instrução e atualizá-los regularmente
Variação das respostas e dependência do fornecedor	Baixa	O mesmo texto pode receber respostas diferentes, e o fornecedor pode alterar ou descontinuar o modelo	Configurar baixa aleatoriedade, repetir os testes a cada troca de versão e manter plano alternativo

Adotar com condições: O LLM resolve a lentidão e a inconsistência atuais, mas atua como apoio, não como decisor. Condições: piloto com chamados anonimizados, comparado à equipe humana, com meta de concordância definida pelo comitê antes de começar; revisão humana dos casos urgentes e de baixa confiança; contrato que proíba o fornecedor de treinar com os dados, conforme a LGPD; e monitoramento periódico. Sem atingir a meta, não adotar (**texto revisado por Claude Sonnet 5.5 Thinking**).